

图象工程（下）

图 象 理 解

（第4版）

章毓晋

清华大学电子工程系 100084 北京



第2单元 景物重建

第6章 立体视觉：双目

➤ 第7章 立体视觉：多目

第8章 景物恢复：多图象

第9章 景物恢复：单图象

对图象的理解先要从图象恢复场景，即
借助2-D图象重建3-D场景

立体视觉是解决3-D重建的一种重要方法
恢复景物就是要恢复景物的本征特性
从形状恢复景物 \Leftrightarrow “从X得到形状”



7.1 水平多目立体匹配

- 视差 d 与两个摄像机间的基线 B 有如下关系

$$d = B \frac{\lambda}{|\lambda - Z|} \approx B \frac{\lambda}{Z} \quad (4.2.3)$$

对给定的物体距离 Z ，视差 d 与基线长度 B 成正比。基线长度 B 越大，对距离的计算将越准确

- 基线长度过长带来的问题
- 需对较大的视差范围进行搜索以寻求匹配点
- 增加了计算量
 - 有周期性重复特征时误匹配概率增加



第7章 立体视觉：多目



7.1 水平多目立体匹配

7.2 正交三目立体匹配


7.3 多目立体匹配

7.4 亚像素级视差计算



7.1 水平多目立体匹配

双目匹配（周期性重复特征）





7.1 水平多目立体匹配

从双目到多目


7.1.1 水平多目图象

7.1.2 倒距离



7.1.1 水平多目图象

通过计算多对图象之间平方差的和 (sum of squared difference, SSD) 来减少总体的误匹配



$$d_i = B_i \frac{\lambda}{Z} \quad i = 1, 2, \dots, M$$



7.1.1 水平多目图象

模型

$$f_i(x) = f[x - d_i] + n_i(x) \quad \{\text{P.160}\}$$

$$\text{SSD} \quad S_d(x; \hat{d}_i) = \sum_{j \in W} \left[f_0(x+j) - f_i(x + \overset{\text{视差估计值}}{\hat{d}_i} + j) \right]^2$$

$$\begin{aligned} E[S_d(x; \hat{d}_i)] &= E \left\{ \sum_{j \in W} \left[f(x+j) - f(x + \hat{d}_i - d_i + j) + n_0(x+j) - n_i(x + \hat{d}_i + j) \right]^2 \right\} \\ &= \sum_{j \in W} \left[f(x+j) - f(x + \underbrace{\hat{d}_i - d_i}_{\text{视差估计值}} + j) \right]^2 + 2N_w \sigma_n^2 \quad \text{极小值} \end{aligned}$$

问题

$$f(x+j) = f(x+p+j) \quad j \in W \quad p: \text{重复周期}$$

$$E[S_d(x; d_i)] = E[S_d(x; d_i + p)] = 2N_w \sigma_n^2 \quad \{\text{P.160}\}$$



7.1.2 倒距离

解决周期性带来的问题

Inverse distance

$$t = \frac{1}{Z}$$

$$t_i = \frac{d_i}{B_i \lambda}$$

$$\hat{t}_i = \frac{\hat{d}_i}{B_i \lambda}$$

SSD
$$S_t(x; \hat{t}_i) = \sum_{j \in W} [f_0(x+j) - f_i(x + B_i \lambda \hat{t}_i + j)]^2$$

$$E[S_t(x; \hat{t}_i)] = \sum_{j \in W} \left\{ \underbrace{f(x+j) - f[x + B_i \lambda (\hat{t}_i - t_i) + j]}_{\text{periodic shift}} \right\}^2 + 2N_w \sigma_n^2$$



7.1.2 倒距离

将对应 M 个倒距离的SSD求和，则得到

SSSD (sum of SSD)

$$S_{t(12...M)}^{(S)}(x; \hat{t}) = \sum_{i=1}^M S_t(x; \hat{t}_i)$$

新度量函数的期望值

$$\begin{aligned} E[S_{t(12...M)}^{(S)}(x; \hat{t})] &= \sum_{i=1}^M E[S_t(x; \hat{t}_i)] \\ &= \sum_{i=1}^M \sum_{j \in W} \left\{ f(x+j) - f[x + B_i \lambda (\hat{t}_i - t_i) + j] \right\}^2 + 2N_w \sigma_n^2 \end{aligned}$$

不确定性问题
依然存在

极小值



7.1.2 倒距离

再考虑前述在 x 和 $x+p$ 处有相同模式的问题

$$E[S_t(x; t_i)] = E\left[S_t\left(x; t_i + \frac{p}{B_i \lambda}\right)\right] = 2N_w \sigma_n^2$$







这里随 B_i 的变化, 虽 t_p 也会变化, 而 t_i 却不变化

$$\begin{aligned} E[S_{i(12)}^{(s)}(x; \hat{t})] &= \sum_{j \in W} \left\{ f(x+j) - f\left[x + B_1 \lambda (\hat{t}_1 - t_1) + j\right] \right\}^2 \\ &\quad + \sum_{j \in W} \left\{ f(x+j) - f\left[x + B_2 \lambda (\hat{t}_2 - t_2) + j\right] \right\}^2 + 4N_w \sigma_n^2 \end{aligned}$$

基线长短不同
极小值位置不同

$$E[S_{i(12)}^{(s)}(x; \hat{t})] > 4N_w \sigma_n^2 = E[S_{i(12)}^{(s)}(x; t)]$$

{例7.1.1}





7.1.2 倒距离

讨论： $f(x)$ 是一个周期函数，其周期是 T 。这样每个 $S_i(x; t)$ 都是 t 的周期函数，其周期是 $T/B_i\lambda$ 。这表明每隔一个 $T/B_i\lambda$ 区段就有一个极小值。当使用两个基线，得到的仍然是 t 的周期函数，但此时的周期 T_{12} 会增加为：

$$T_{12} = \text{LCM}\left(\frac{T}{B_1\lambda}, \frac{T}{B_2\lambda}\right)$$

这里LCM代表最小公倍数。可见 T_{12} 不会比 T_1 或 T_2 小。进一步，通过选择合适的基线 B_1 和 B_2 ，有可能使得在匹配搜索区间仅有一个极小值



7.2 正交三目立体匹配

另一类多目（不在一条直线上）立体匹配

7.2.1 基本原理

7.2.2 基于梯度分类的正交匹配



7.2.1 基本原理

- 水平多目解决了灰度周期性模式带来的问题
- 另一个问题：灰度光滑区域造成的误匹配
- 水平多目解决不了光滑区域造成的误匹配

➤ 正交三目 {P. 164}

$$f_L(x,y) = f(x,y) + n_L(x,y)$$

$$f_R(x,y) = f(x - d_h, y) + n_R(x,y)$$

$$f_T(x,y) = f(x, y - d_v) + n_T(x,y)$$




图 7.2.1 正交三目图像的拍摄位置



7.2.1 基本原理

- 设 $d_h = d_v = d$ ，则对应水平方向和垂直方向的SSD分别为：

$$S_h(x, y; \hat{d}) = \sum_{j, k \in W} \left[f_L(x + j, y + k) - f_R(x + \hat{d} + j, y + k) \right]^2$$
$$S_v(x, y; \hat{d}) = \sum_{j, k \in W} \left[f_L(x + j, y + k) - f_T(x + j, y + \hat{d} + k) \right]^2$$

- 正交视差度量函数

$$O^{(S)}(x, y; \hat{d}) = S_h(x, y; \hat{d}) + S_v(x, y; \hat{d})$$



7.2.1 基本原理

$O^{(s)}(x, y; \hat{d})$ 的期望值:

$$\begin{aligned} E\left[O^{(s)}(x, y; \hat{d})\right] &= \sum_{j, k \in W} \left[f(x+j, y+k) - f(x+\hat{d}-d+j, y+k) \right]^2 \\ &\quad + \sum_{j, k \in W} \left[f(x+j, y+k) - f(x+j, y+\hat{d}-d+k) \right]^2 \\ &\quad + 4N_w\sigma_n^2 \end{aligned}$$

- 在正确视差值处, $E[O^{(s)}(x, y; \hat{d})]$ 取得极小值

$$E\left[O^{(s)}(x, y; d)\right] = 4N_w\sigma_n^2$$



7.2.1 基本原理

正交三目立体匹配方法不仅能减少由于光滑区域造成的误匹配，也能减少周期性模式造成的误匹配，且极小值次数减少

$$f(x+j, y+k) = f(x+j+T_x, y+k+T_y) \quad (7.2.7) \quad (7.2.8)$$


$$\begin{aligned} E[O^{(s)}(x, y; \hat{d})] &= E[S_h(x, y; \hat{d} + T_x) + S_v(x, y; \hat{d} + T_y)] \\ &= E[O^{(s)}(x, y; \hat{d} + T_{xy})] \end{aligned}$$

$$\boxed{T_{xy} = \text{LCM}(T_x, T_y)} \quad \{(7.2.10)\}$$



7.2.2 基于梯度分类的正交匹配

1. 算法流程（不必计算两幅完整的视差图）





7.2.2 基于梯度分类的正交匹配

减少运算复杂度

$$G_h(x, y) = \sum_{i=1}^{W/2} \sum_{j=y-W/2}^{y+W/2} |f_L(x-i, j) - f_L(x+i, j)|$$

$$G_v(x, y) = \sum_{j=1}^{W/2} \sum_{i=x-W/2}^{x+W/2} |f_L(x, y-j) - f_L(x, y+j)|$$

- 如果 $G_h > G_v$ ，则将该像素划归为水平区域，借助水平图象对进行搜索匹配
- 如果 $G_h < G_v$ ，则将该像素划归为垂直区域，借助垂直图象对进行搜索匹配




7.2.2 基于梯度分类的正交匹配

2. 关于模板尺寸的讨论


梯度模板：计算梯度方向

过小？

不跨越边界，
难以区分两种区域



足够大



大模板计算量大，
难以确定方向




7.2.2 基于梯度分类的正交匹配


2. 关于模板尺寸的讨论

匹配（搜索）模板：计算灰度区域相关
纹理与光滑

不能
过小
以免
平滑
区的
随机
性



纹理与纹理




模板
总在
纹理
区域
内，
大小
均可



7.2.2 基于梯度分类的正交匹配

3. 正交三目视差图校正 (参考6.4节)





7.3 多目立体匹配

更一般的情况：不止三目，各目间连线不正交

7.3.1 任意排列三目立体匹配

7.3.2 正交多目立体匹配



7.3.1 任意排列三目立体匹配

- 在三目立体成象系统中，每个象平面上有两条极线，它们的交点也是物点 W 与象平面的交点
- 给定物点 W 与任两个光心点确定一个极平面
- 极平面与对应光心象平面的交线即为极线。匹配总是在极线上进行的




图 7.3.1 任意排列三目立体成像系统



7.3.1 任意排列三目立体匹配

- 三个象平面的光心 C_1 , C_2 和 C_3 确定一个**三焦平面**
- 如果3个摄像机都观察物点 W , 得到的3个象点的坐标分别为 p_1 , p_2 , p_3
参见(6.2.8)
- 本质矩阵方程: 三个方程不独立
- 任意两个方程都是独立的
- 当本质矩阵已知时, 用任意两个象点的坐标就可预测出第3个象点的坐标

$$p_1^T E_{12} p_2 = 0$$

$$p_2^T E_{23} p_3 = 0$$

$$p_3^T E_{31} p_1 = 0$$



7.3.1 任意排列三目立体匹配

- 增加第3个摄像机可以消除许多仅用双目图像匹配所产生的不确定性

{P. 171}

先利用两幅图像建立对应关系再用第三幅图像来验证




图 7.3.2 第 3 幅图像帮助减少不确定性



7.3.1 任意排列三目立体匹配

1. 基于极线的三目匹配

(1) $L_1^1 \Leftrightarrow L_1^2$, $a \Leftrightarrow b$ or c ?

L_j^i 第*i*幅图象
第*j*条极线

(2) $b: L_2^2 \Leftrightarrow L_2^3$; $c: L_3^2 \Leftrightarrow L_3^3$

(3) $L_1^1 \Leftrightarrow L_1^3$, $a \Leftrightarrow d$, $b \Leftrightarrow d$, $\therefore a \Leftrightarrow b$






图 7.3.3 基于极线的三目匹配示意




7.3.1 任意排列三目立体匹配


2. 基于边缘线段的三目匹配

线段邻接图: 结点 \leftrightarrow 边缘线段, 弧 \leftrightarrow 线段邻接


- (1) 对 G_1 中的 S_1 , 计算 S_1 的中点 p_1 所在 G_2 中的极线 L_{21} , p_1 在 G_2 中的对应点 p_2 将在极线 L_{21} 上



图像 1



图像 2



图像 3

图 7.3.4 基于边缘线段的三目匹配



6.3.1 任意排列三目立体匹配

- (2) 现在考虑 G_2 中与极线 L_{21} 相交的线段 S_2
设 L_{21} 与 S_2 的交点为 p_2 ，对每个线段 S_2 ，比较它
与线段 S_1 的长度和方向，如果它们之间的差值
小于给定的阈值（长度接近且朝向接近），
则认为它们可能匹配： $S_1 \Leftrightarrow S_2$




图 7.3.4 基于边缘线段的三目匹配



6.3.1 任意排列三目立体匹配

- (3) 对每个可能匹配的线段，进一步计算其在 G_3 中的极线 L_{32} ，设它与 p_1 在 G_3 中的极线 L_{31} 的交点为 p_3 。在 p_3 附近搜索与线段 S_1 和 S_2 的长度和方向的差值小于给定阈值的线段 S_3 ，如果可找到，则 S_1 ， S_2 和 S_3 组成一组匹配线段




图 7.3.4 基于边缘线段的三目匹配



7.3.1 任意排列三目立体匹配

3. 基于曲线的三目匹配

T_j^i 第 i 幅图象
第 j 条曲线

- (1) 任选 T_1^1 上一点 p_1^1 , 考虑 G_2 中的极线 L_{21}
- (2) 极线 L_{21} 与曲线 T_1^2 和 T_2^2 交于点 p_1^2 和 p_2^2
- (3) 如果点 p_1^1 和 p_1^2 对应, T_1^3 上还可找到点 p_1^3




图 7.3.5 基于曲线的三目匹配



7.3.1 任意排列三目立体匹配



3. 基于曲线的三目匹配

找不到? \Rightarrow 点 p_1^1 和 p_1^2 不应是对应的

① 没有很接近 p_1^3 的点


② 有通过点 p_1^3 的曲线，但其切线单位矢量与预期不符

③ 有通过点 p_1^3 的曲线，且其切线单位矢量与预期相符，但其曲率与预期不符



7.3.2 正交多目立体匹配

推广： 同时消除周期模式和光滑区域的影响。结合单方向多目图象分析和正交三目图象分析的方法






7.3.2 正交多目立体匹配



推广： 同时消除周期模式和光滑区域的影响。结合单方向多目图象分析和正交三目图象分析的方法





7.3.2 正交多目立体匹配

推广：四目立体匹配

给出四焦张量和任意3条通过3个象点的直线，
就可以推出第4个象点的位置




图 7.3.8 4 目立体匹配示意



7.4 亚像素级视差计算

- 视差函数

$$f_R(x, y) = f_L[x + d_r(x, y), y] + n_L(x, y)$$

- 匹配窗口内: $d_r(u, v)$ 是变量, 将 $f_L[u + d_r(u, v), v]$ 在 $d_r(0, 0)$ 处展开成一阶泰勒级数形式

$$f_L[u + d_r(u, v), v] \approx f_L[u + d_r(0, 0), v] + [d_r(u, v) - d_r(0, 0)] \frac{\partial}{\partial u} f_L[u + d_r(0, 0), v] + n_L(u, v)$$

$$f_R(u, v) - f_L[u + d_r(0, 0), v] \approx [d_r(u, v) - d_r(0, 0)] \frac{\partial}{\partial u} f_L[u + d_r(0, 0), v] + n_L(u, v)$$



7.4 亚像素级视差计算

- 窗口内视差的统计分布模型（局部视差）

$$d_r(u, v) - d_r(0, 0) \sim N(0, k_d \sqrt{u^2 + v^2}) \quad \{\text{P.175}\}$$

- 图象强度的一阶偏微分统计模型（局部强度）

$$\frac{\partial}{\partial u} f_L(u, v) \sim N(0, k_f)$$

- 立体图象对之间的强度差值统计分布

$$n_S(u, v) = f_R(u, v) - f_L[u + d_r(0, 0), v]$$

$$\text{近似高斯白噪声 } n_S(u, v) \sim N(0, 2\sigma_n^2 + k_f k_d \sqrt{u^2 + v^2})$$



7.4 亚像素级视差计算

- 分析: $n_s(u, v) \sim N\left(0, 2\sigma_n^2 + k_f k_d \sqrt{u^2 + v^2}\right)$

① 来自于图象噪声的常量

② 来自于匹配窗口内的局部不确定性

- 假设 $d_0(x, y)$ 是正确视差 $d_r(x, y)$ 的初始估计, 将 $f_L[u + d_r(0, 0), v]$ 在 $u + d_0(x, y)$ 处阶泰勒级数展开

$$f_L[u + d_r(0, 0), v] = f_L[u + d_0(0, 0), v] + \Delta d \frac{\partial}{\partial u} f_L[u + d_0(0, 0), v]$$


$$\Delta d = d_r(0, 0) - d_0(0, 0)$$

$$n_s(u, v) = f_R(u, v) - f_L[u + d_0(0, 0), v] - \Delta d \frac{\partial}{\partial u} f_L[u + d_0(0, 0), v]$$



7.4 亚像素级视差计算

- (1) 先用任意像素级立体匹配算法求得视差初值
 - (2) 对每个像素点，选择具有最小不确定性的视差估计窗口并计算视差修正量 Δd
 - (3) 计算达到收敛或达到预定迭代次数时，停止
- 将亚像素级算法推广到正交三目立体匹配






7.4 亚像素级视差计算

视差计算与体积测量

表 7.4.1 不同方法对锥体体积的计算结果

	真实值	像素级	亚像素级（双目）	亚像素级（正交三目）
绝对体积/ m^3	2.304	3.874	2.834	2.467
相对误差	—	68%	23%	7%

亚像素级误差





联系信息



- ✎ 通信地址：北京清华大学电子工程系
- ✎ 邮政编码：100084
- ✎ 办公地址：清华大学，罗姆楼，6层305室
- ✎ 办公电话：(010) 62798540
- ✎ 传真号码：(010) 62770317
- ✎ 电子邮件：zhang-yj@tsinghua.edu.cn
- ✎ 个人主页：oa.ee.tsinghua.edu.cn/~zhangyujin/